

L16 · Δυναμικός Προγραμματισμός III

Ευθυγράμμιση Συμβολοσειρών

Algorithms Class Hub

Αλγόριθμοι και Πολυπλοκότητα (K17) · ΕΚΠΑ

Ομοιότητα συμβολοσειρών και απόσταση επεξεργασίας (*edit distance*), ο αλγόριθμος ευθυγράμμισης ως συντομότερο μονοπάτι σε πλέγμα, και η ευθυγράμμιση σε γραμμικό χώρο κατά *Hirschberg*.

1 Τι θα δούμε

Πόσο **όμοιες** είναι δύο συμβολοσειρές; Το ερώτημα ακούγεται απλό, αλλά είναι η βάση για το `unix diff`, για την αναγνώριση φωνής, και για τη σύγκριση ακολουθιών DNA. Η απάντηση — η **απόσταση επεξεργασίας** — είναι ένα κομψό DP. Και θα δούμε δύο βαθιές ιδέες:

1. Το DP πλέγμα είναι στην πραγματικότητα **γράφημα** — και η βέλτιστη λύση είναι ένα **συντομότερο μονοπάτι**.
2. Με συνδυασμό DP **και** διαίρει-και-κυρίευε, μπορούμε να λύσουμε το πρόβλημα σε **γραμμικό χώρο** (*Hirschberg*).

2 Ομοιότητα συμβολοσειρών

Δες τις δύο λέξεις:

```
o c c u r r a n c e  
o c c u r e n c e
```

Είναι ολοφάνερα «η ίδια λέξη με λάθη». Αλλά πώς το **ποσοτικοποιείς**; Η ιδέα: μέτρα πόσες **στοιχειώδεις αλλαγές** χρειάζονται για να μετατρέψεις τη μία στην άλλη.

Κλειδί

Απόσταση επεξεργασίας (*edit distance*) — [Levenshtein 1966, Needleman-Wunsch 1970]. Δύο είδη «κόστους»:

- **κόστος κενού** δ — αφήνεις έναν χαρακτήρα **αταίριαστο** (μια εισαγωγή ή διαγραφή).
- **κόστος σύγκρουσης** α_{xy} — ταιριάζεις δύο **διαφορετικούς** χαρακτήρες $x \neq y$ (μια αντικατάσταση). Αν $x = y$, το κόστος είναι 0.

Συνολικό κόστος = άθροισμα όλων των κενών και των συγκρούσεων.

3 Ευθυγράμμιση συμβολοσειρών

Κλειδί

Ευθυγράμμιση (alignment) M δύο συμβολοσειρών $X = x_1 \cdots x_m$ και $Y = y_1 \cdots y_n$: ένα σύνολο διατεταγμένων ζευγών $x_i - y_j$ τέτοιο ώστε:

- κάθε χαρακτήρας ανήκει σε **το πολύ ένα** ζεύγος, και
- τα ζεύγη **δεν διασταυρώνονται** — τα $x_i - y_j$ και $x_{i'} - y_{j'}$ διασταυρώνονται αν $i < i'$ αλλά $j > j'$.

$$\text{κόστος}(M) = \sum_{(x_i, y_j) \in M, x_i \neq y_j} \alpha_{x_i y_j} + \sum_{x_i \text{ αταίριαστο}} \delta + \sum_{y_j \text{ αταίριαστο}} \delta$$

Διαίσθηση

«Δεν διασταυρώνονται» σημαίνει ότι αν διαβάσεις και τις δύο λέξεις από αριστερά προς δεξιά, τα ζεύγη διατηρούν τη σειρά τους — δεν μπερδεύεσαι. **Στόχος:** βρες την ευθυγράμμιση **ελάχιστου κόστους**.

4 Η αναδρομή

Ορίζουμε $\text{OPT}(i, j) =$ ελάχιστο κόστος ευθυγράμμισης των προθεμάτων $x_1 \cdots x_i$ και $y_1 \cdots y_j$. Κοιτάμε τους τελευταίους χαρακτήρες x_i, y_j — υπάρχουν **τρεις** δυνατότητες:

- **Ταίριασμα** x_i με y_j : πληρώνεις $\alpha_{x_i y_j}$ (ή 0 αν ίδιοι) + το βέλτιστο για $x_1 \cdots x_{i-1}, y_1 \cdots y_{j-1}$.
- **Το x_i αταίριαστο**: πληρώνεις κενό δ + το βέλτιστο για $x_1 \cdots x_{i-1}, y_1 \cdots y_j$.
- **Το y_j αταίριαστο**: πληρώνεις κενό δ + το βέλτιστο για $x_1 \cdots x_i, y_1 \cdots y_{j-1}$.

Κλειδί

$$\text{OPT}(i, j) = \begin{cases} j \cdot \delta & i = 0 \\ i \cdot \delta & j = 0 \\ \min \begin{cases} \alpha_{x_i y_j} + \text{OPT}(i-1, j-1) \\ \delta + \text{OPT}(i-1, j) \\ \delta + \text{OPT}(i, j-1) \end{cases} & \text{αλλιώς} \end{cases}$$

Οι βασικές περιπτώσεις: ευθυγράμμιση με την **κενή** συμβολοσειρά κοστίζει ένα κενό ανά χαρακτήρα.

Ευθυγράμμιση(m, n, x, y, δ, α):

Για i = 0 έως m: M[i, 0] <- i*δ

Για j = 0 έως n: M[0, j] <- j*δ

Για i = 1 έως m:

Για j = 1 έως n:

M[i, j] <- min(α(x_i, y_j) + M[i-1, j-1],
δ + M[i-1, j],
δ + M[i, j-1])

επίστρεψε M[m, n]

Παράδειγμα. $x = \text{GAC}$, $y = \text{AGC}$, με $\delta = 1$ και $\alpha_{xy} = 1$ για $x \neq y$:

	$\emptyset$	A	G	C
$\emptyset$	0	1	2	3
G	1	1	1	2
A	2	1	2	2
C	3	2	2	2

Η απόσταση επεξεργασίας είναι $M[3, 3] = 2$.

Πολυπλοκότητα: $\Theta(mn)$ χρόνος και $\Theta(mn)$ χώρος.

5 Το DP πλέγμα είναι γράφημα

Εδώ έρχεται η βαθιά ιδέα. Φτιάχνουμε ένα **γράφημα απόστασης επεξεργασίας**: μια κορυφή για κάθε ζεύγος (i, j) , με ακμές:

- **δεξιά** $(i, j - 1) \rightarrow (i, j)$ — κόστος δ (κενό στο X),
- **κάτω** $(i - 1, j) \rightarrow (i, j)$ — κόστος δ (κενό στο Y),
- **διαγώνια** $(i - 1, j - 1) \rightarrow (i, j)$ — κόστος $\alpha_{x_i y_j}$ (ταίριασμα).

Κλειδί

Με αυτές τις ακμές, το $\text{OPT}(i, j)$ ισούται **ακριβώς** με το μήκος του **συντομότερου μονοπατιού** από την κορυφή $(0, 0)$ στην (i, j) . Η απόσταση επεξεργασίας είναι το συντομότερο μονοπάτι $(0, 0) \rightarrow (m, n)$.

6 Ευθυγράμμιση σε γραμμικό χώρο — Hirschberg

Ο πίνακας $\Theta(mn)$ είναι το πρόβλημα: στην υπολογιστική βιολογία $m = n = 100.000$, και ένας πίνακας 10^{10} κελιών **δεν χωράει** στη μνήμη.

6.1 Πρώτη παρατήρηση — η τιμή σε γραμμικό χώρο

Για να υπολογίσεις τη γραμμή $\text{OPT}(i, \cdot)$ χρειάζεσαι **μόνο** την προηγούμενη γραμμή $\text{OPT}(i - 1, \cdot)$. Άρα η **τιμή** $\text{OPT}(m, n)$ υπολογίζεται σε $O(m + n)$ χώρο και $O(mn)$ χρόνο, κρατώντας δύο γραμμές κάθε φορά.

Προσοχή

Αλλά — έτσι χάνεις τον υπόλοιπο πίνακα, και η **ίδια η ευθυγράμμιση** δεν ανακτάται με το συνηθισμένο πέρασμα προς τα πίσω. Χρειάζεται έξυπνη ιδέα.

6.2 Η ιδέα του Hirschberg (1975) — διαίρει και κυρίευε + DP

Δουλεύουμε στο γράφημα απόστασης. Ορίζουμε:

- $f(i, j) =$ συντομότερο μονοπάτι από $(0, 0)$ στο (i, j) — δηλαδή $\text{OPT}(i, j)$.

- $g(i, j)$ = συντομότερο μονοπάτι από (i, j) στο (m, n) — υπολογίζεται **όμοια**, αντιστρέφοντας τις ακμές.

Κλειδί

Το κόστος του συντομότερου μονοπατιού $(0, 0) \rightarrow (m, n)$ που περνά από την κορυφή (i, j) είναι ακριβώς $f(i, j) + g(i, j)$.

Διαλέγουμε τη **μεσαία στήλη** $j = n/2$. Έστω q ο δείκτης γραμμής που ελαχιστοποιεί την ποσότητα $f(q, n/2) + g(q, n/2)$. Τότε **υπάρχει** βέλτιστη ευθυγράμμιση που περνά από την κορυφή $(q, n/2)$.

Διαιρεί: βρες το q (με DP σε γραμμικό χώρο, υπολογίζοντας τη στήλη $f(\cdot, n/2)$ και $g(\cdot, n/2)$). Ευθυγράμμισε το $(q, n/2)$.

Κυρίευε: λύσε αναδρομικά τα **δύο μισά** — το πάνω-αριστερά ορθογώνιο $(0, 0) - (q, n/2)$ και το κάτω-δεξιό $(q, n/2) - (m, n)$.

Κλειδί

Πολυπλοκότητα: $O(m + n)$ **χώρος** και $O(mn)$ **χρόνος**. Ο χρόνος μένει $O(mn)$ γιατί κάθε επίπεδο της αναδρομής δουλεύει σε ορθογώνια συνολικού εμβαδού που **υποδιπλασιάζεται** — $mn + mn/2 + mn/4 + \dots = O(mn)$.

Διαίσθηση

Γιατί είναι όμορφο: συνδυάζει **δύο** από τα μοντέλα του μαθήματος. Το DP βρίσκει τη μεσαία κορυφή· το διαιρεί-και-κυρίευε σπάει το πρόβλημα γύρω της. Κανένα από τα δύο μόνο του δεν θα έδινε γραμμικό χώρο.

Ανακεφαλαίωση

Τι κρατάμε από αυτή τη διάλεξη

1. **Απόσταση επεξεργασίας** — ελάχιστο κόστος μετατροπής μιας συμβολοσειράς σε άλλη, με κόστος κενού δ και κόστος σύγκρουσης α .
2. **Ευθυγράμμιση** = μη-διασταυρούμενα ζεύγη χαρακτήρων. Αναδρομή με **τρεις** περιπτώσεις: ταίριασμα (διαγώνια), κενό στο X (κάτω), κενό στο Y (δεξιά). Χρόνος & χώρος $\Theta(mn)$.
3. Το DP πλέγμα είναι **γράφημα**: $\text{OPT}(i, j)$ = συντομότερο μονοπάτι $(0, 0) \rightarrow (i, j)$.
4. **Hirschberg** — συνδυασμός DP + διαιρεί-και-κυρίευε. Με f (εμπρός) και g (πίσω), βρες την κορυφή της μεσαίας στήλης που ελαχιστοποιεί $f + g$, και αναδρομή. $O(m + n)$ χώρος, $O(mn)$ χρόνος.